

# Short-Term Load Forecasting Based on Deep Learning Model

## 딥러닝 모델 기반 단기 전력수요 예측

Dohyun Kim · Ho Jin-Jo · Myung Su Kim · Jae Hyung Roh · Jong-Bae Park

김도현\* · 조호진\* · 김명수\* · 노재형\* · 박종배†

### Abstract

This paper presents a Short-Term Long-short term memory Convolutional neural network(STLC) Model that is combined with Convolutional Neural Network(CNN) and Long-Short Term Memory(LSTM). CNN model predicts load pattern using past load profile, LSTM model forecasts load variation depending on temperature and time index. STLC model's output is hourly load data to combine two model's outputs. The input parameters of STLC model are composed of time index, weighted weather data, past load data. Weights are calculated based on electricity consumption by main region in South Korea and reflects in the weather data. STLC model is trained with data from 2013 through 2017 and is verified with data from 2018. The STLC model forecasts 1-day hourly load data. Simulation results obtained show the comparison of actual and forecasted load data and also compare with other methods in MAPE(Mean Absolute Percentage Error) to prove accuracy of the proposed model.

### Key Words

Deep Learning, Short-Term Load Forecasting, CNN, LSTM

## 1. 서론

전력수요예측은 예측기간에 따라서 초단기, 단기, 중기, 장기로 구분할 수 있다. 단기 전력수요예측은 1시간에서 1주일까지의 미래 전력수요예측을 수행한다. 단기 전력수요예측의 결과는 전력시장의 발전가격 결정, 예비력 및 송전용량 확보를 위한 발전기 운영 계획 등에 활용된다. 따라서 정확한 단기 전력수요예측은 안정적인 전력시스템의 운영과 효율적인 전력시장 운영에 기여한다[1].

단기 전력 수요 예측 방법은 크게 통계적 기법과 인공지능 기법으로 나눌 수 있다. 통계적 기법은 현재까지의 전력 수요량과 관련 정보들의 수학적 조합을 이용하여 미래의 전력 수요량을 예측하는 기법으로 지수평활법, 시계열 분석법 등이 있다. 지수평활법은 현재 시점에 대해 예측된 수요량과 실제 수요량의 가중 평균으로 미래의 수요량을 예측하는 방법으로 시계열 데이터의 추세와 계절성을 고려한 Holt-Winters 지수평활 모델이 대표적이다[2].

시계열 분석 모델에는 현재의 시계열이 과거의 관측 값에 영향을 받는 자기회귀 모델(Autoregressive model : AR), 시계열이 과거의 오차항으로 표현되는 이동평균 모델(Moving Average model : MA), AR 모델과 MA모델을 혼합한 자기회귀이동평균

모델(Autoregressive Moving Average model : ARMA), 비정상 시계열 차분연산을 통해 정상 시계열로 변화시켜 ARMA 모델에 포함시키는 ARIMA 모델이 있다[3].

인공지능 기법에는 일반적으로 인공신경망, 웨이브렛 변화, 서포트 벡터머신, 하이브리드 모델 등 다양한 모델들이 있다. 인공신경망은 학습 속도가 빠르기 때문에 단기 전력 수요 예측 시 많이 활용되지만, 대량의 데이터가 주어질 경우 과적합 문제가 발생할 수 있으며 연결 가중치 조정 시 학습시간이 길어질 수 있다는 단점이 있다[4]. 이와 같은 문제를 극복하면서 예측 정확도를 향상시키기 위해 상태공간 모델[5], 웨이브렛 변화[6], 하이브리드 모델[7-8] 등이 연구 되고 있다. 입력 변수와 출력 변수 간의 관계를 이해하기 쉬운 서포트 벡터머신 기반 수요예측에 대한 연구 또한 활발히 진행되고 있다[1][9].

해외의 전력 수요 예측 연구 및 개발 현황에 대해 살펴보면 PJM은 신경 회로망 모델과 유사 전력 패턴 모델을 사용하여 단기 전력 수요 예측 및 가격 결정에 활용하고 있다. 이 때 활용되는 변수는 평일-주말 요일 분류, 공휴일 및 기타 특수 상황이 발생한 날짜, 기상 관측 자료, 전력 수요 조정량 등이다[10].

CAISO는 신경 회로망 모델과 ARIMA 기반의 ALFS(Automated Load Forecasting System) 프로그램을 활용하고 있으며, 기상자료는 24개의 기상관측지점의 9일 예보자료로, 기온, 이슬점, 풍

† Corresponding Author : Dept. of Electrical and Electrical Engineering, Konkuk University, Korea  
E-mail: sowing12@naver.com

\*Dept. of Electrical and Electrical Engineering, Konkuk University, Korea

Received : March 20, 2019 Accepted : July 31, 2019

Copyright © The Korean Institute of Electrical Engineers

This is an Open-Access article distributed under the terms of the Creative Commons Attribution Non-Commercial License (<http://creativecommons.org/licenses/by-nc/4.0/>) which permits unrestricted non-commercial use, distribution, and reproduction in any medium, provided the original work is properly cited.

속, 조도 등을 사용하고 매시간별로 기상 실측자료를 업데이트 한다[10].

한국 전력 거래소는 단기 전력 수요 예측 프로그램(KSLF : KPX Short-Term Load Forecaster)을 수요예측 업무에 사용하고 있다. KSLF는 과거 전력 수요 패턴 분석을 통해 기온과 전력 수요 특성을 고려한 수요 예측을 시행한다. 평일과 주말은 기상 요인을 반영한 지수 평활 기법을 사용하며, 공휴일은 퍼지 선형 회귀 분석 기법을 활용하여 기온 변화를 고려하지 않은 수요를 예측한다. 한국 전력거래소에서 수요 예측에 사용하는 데이터는 시간 단위 전력 데이터와 일일 최고/최저 기온, 특수 상황에 대한 조사 조업률이다. 지역별 전력 수요가 아닌 전국 단위의 전력 수요를 예측하기 때문에, 전국 8개 도시 기온을 이용하여 전국 대표기온을 추정하여 수요 예측에 반영한다[10].

국내 단기 수요 예측 관련 연구에는 필수 입력 값만을 가지는 최소 구조 신경회로망 알고리즘 기반 여름철 온도 민감도를 이용하여 얻은 수요 예측값을 신경망의 입력값으로 추가하여 정확도 개선 모델[11], 요일 특성을 2차 함수로 표현하여 반영한 회귀 모델[12], 구조 뱅크로부터 초기화되는 뉴로-퍼지 모델을 이용하여 1시간, 1일, 1주 단위의 전력 수요를 예측하는 모델 [13], 과거 전력 수요와 날씨 요소간의 상관관계 측정을 통한 입력변수 선별 및 전력 피크에 따른 온도 민감도 차등 반영을 통한 인공지능망 기반 단기 수요 예측 모델[14]과 같은 선행 연구들이 있다.

본 논문은 기온의 변화에 따른 전력 수요의 변화와 과거 전력 수요의 패턴을 이용한 딥 러닝 기반(CNN, LSTM) 단기 수요 예측 모델(STLC 모델)을 제시하고자 한다. 2013년-2017년까지의 전력 수요 데이터와 가중치를 반영한 기후데이터(기온, 습도, 이슬점 온도)를 입력 데이터로 사용하였으며 2018년 하절기 및 동절기까지의 데이터를 가지고 모델의 성능을 검증하였다.

본 논문의 2장에서는 논문에서 사용될 모델에 대해서 서술하였으며, 3장에서는 사례 연구에 관해 서술하였고, 마지막으로 결론에 대해서 서술하였다.

## 2. 모델 설명

### 2.1 Convolutional Neural Network 모델

CNN은 생물의 시각처리과정을 모방하여 패턴의 크기나 위치가 바뀌어도 인식을 할 수 있다는 장점이 있는 모델로 Neognitron(Fukushima, 1980)모델에 기반을 두고 있다. 이 모델이 발전되어서 LeCun et al.(1998)을 통하여 현재 사용되고 있는 합성곱 신경망이 널리 쓰이는 계기가 되었다. 이러한 합성곱 신경망은 문자인식과 다양한 형태의 영상인식 등에 성공적으로 적용되어 왔다. 특히 음성인식, 문서읽기, 그리고 필기체문자인식 등의 분야에서는 1990년대 초반부터 적용되어왔다[15].

CNN은 하위 계층부터 상위 계층을 지나면서 이미지가 가지는 특징을 추출한다. 하위 계층에서는 복수의 합성곱과 풀링을

통해 feature map을 구성한다. 합성곱 계층에서는 이전 계층의 복수의 출력 값을 입력으로 받아 가중치 연산과정을 수행하고 풀링 계층에서는 블록 내의 특징값 중 최대값을 취함으로써 위치에 상관없이 특징이 되는 값은 보존하고 특징 맵의 크기를 줄여 연산을 빠르게 해주는 역할을 한다. 상위 계층에서는 이전 계층에서 추출된 데이터를 가지고 다시 특징을 사용하여 최종 출력값을 도출하게 된다[16].

$N \times N$ 의 입력 이미지가 합성곱 계층에 연결되어 있고,  $m \times m$ 의 합성곱 필터가 있을 때 합성곱 계층의 크기는  $(N-m+1) \times (N-m+1)$ 이 된다. 각 합성곱 계층은 이전 계층의 출력으로부터 나온 값을 입력으로 한다. 이전 계층의 입력 값들을 받아 합성곱 필터로 가중치를 계산한다. 이로 인해 출력된 값을 활성화 함수로 계산한다. 모든 합성곱 계층을 지난 후 마지막에 fully connected layer를 통해 출력값을 도출한다. 이미지의 특징을 추출하기 위해 가중치인 합성곱 필터를 훈련시킨다[17].




그림 1 CNN 모델 프로세스

Fig. 1 CNN model process

### 2.2 Long-Short Term Memory 모델

LSTM은 1997년 Hochreiter & Schmidhuber에 의해 제안된 순환신경망 구조이며 현재까지도 가장 주요적인 순환신경망으로 자리 잡고 있다. LSTM은 전통적인 순환신경망 구조에서 은닉 계층의 유닛들을 LSTM 블록(Block)으로 대체시킨 형태와 같다.

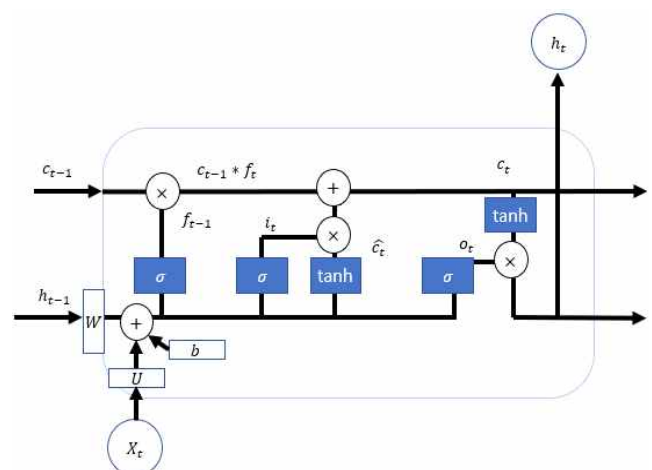


그림 2 LSTM 구조

Fig. 2 LSTM structure

그림 2에서 나타내고 있는 LSTM 블록들은 기존의 은닉유닛들과 마찬가지로 재귀적 구조를 띄며, 블록 내부에는 기억소자(Memory Cell)와 입력게이트, 망각 게이트, 출력 게이트 3종류

의 게이트들로 이루어져있다. 망각 게이트와 입력게이트를 통해 조절된 과거의 정보와 새로운 정보는 소자변수로 계산된다. 마지막으로 출력게이트는 필터링을 통해 계산된 소자변수의 유용한 정보를 최종 은닉 변수로 출력하게 된다. LSTM은 전통적인 순환신경망과 마찬가지로 은닉변수를 거쳐 최종 출력값을 계산하지만, 은닉변수의 계산 과정은 앞에 거론된 게이트들을 적절하게 이용해서 정보의 흐름을 조절한다. LSTM의 역방향 계산(Backward Pass)은 전통적인 순환신경망과 같이 Back Propagation Through Time (BPTT)를 통해 계산된다[18].

## 2.3 Short Term LSTM-CNN(STLC) 모델

### 2.3.1 입력 데이터 구성

전력 수요 예측을 위한 모든 데이터 값의 크기가 모두 다르기 때문에, 데이터의 범위를 일치시키거나 분포를 유사하게 만들어야한다. 또한 신경망은 입출력의 데이터의 크기가 작아야 학습이 효과적이기 때문에, 모든 독립변수인 입력 데이터를 다음과 같이 정규화하였다.

$$\tilde{d}_i = \frac{d_i - \min(1:d)}{\max(1:d) - \min(1:d)} \quad (1)$$

$d_i$ 는 각 요소의 데이터이며,  $\min(1:d)$ 은 각 요소 중 가장 작은 값,  $\max(1:d)$ 은 각 요소 중 가장 큰 값을 나타낸다.

표 1 지역별 가중치

Table 1 Weighted by regions

지역	가중치
서울	0.175
인천	0.09
대전	0.035
대구	0.057
울산	0.121
광주	0.032
부산	0.077
경기	0.412

본 논문에서 사용하는 입력 데이터는 기후 데이터(기온, 습도, 이슬점 온도), 요일, 과거 전력 수요 실측치이다. 기후 데이터의 경우 한국 전력에서 제공하는 주요 8개 지역(서울, 인천, 대전, 대구, 울산, 광주, 부산, 경기)의 2017년 지역별 전력 사용량 기반으로 하여 가중치를 선정하였고, 본 가중치를 기후 데이터에 반영하였다.

### 2.3.2 모델 구성

본 논문에서 제안하는 모델은 전력수요패턴 및 기후 변화에 따른 수요 변동을 반영하기 위해 합성곱 신경망 및 LSTM 모델을 사용하여 병렬적 예측을 수행하고 각 모델의 가중치를 반

영하여 최종 예측값을 출력하는 모델을 제안한다.

본 논문에서 사용한 CNN의 경우 3개의 합성곱 계층과 풀링 계층으로 구성된다. 이러한 합성곱 계층의 필터 크기 및 개수는 표 2와 같으며 풀링 계층의 영역은  $2 \times 2$ 로 모두 동일하게 구성하였고, 마지막 계층은 Fully-connected 계층으로 구성되어 있다.

표 2 제안 CNN 모델 구조

Table 2 The proposed structure of CNN model

계층	필터 크기 및 갯수
합성곱 계층 #1	$3 \times 3 \times 4$
합성곱 계층 #2	$3 \times 3 \times 4$
합성곱 계층 #3	$3 \times 3 \times 2$

전력 수요는 요일, 시간, 계절 등에 따라 다양한 패턴을 가진다. 일반적으로 전력수요는 평일(화요일~금요일), 월요일, 토요일, 일요일로 나눈다. 평일은 주로 월요일~금요일을 뜻하지만 월요일의 경우 주말의 영향으로 인해 새벽시간에 전력수요가 다른 평일에 비해 낮은 특성을 보인다.




그림 3 제안 LSTM 구성

Fig. 3 The proposed structure of LSTM

이러한 특성을 고려하기 위해 본 논문에서 제안하는 모델은 두 개의 그룹으로 나누어 각 그룹의 데이터 구성을 달리하였고, 요일별 특성을 반영하기 위해 각 요일별 모델을 따로 구축하였다. 여기서 두 개의 그룹은 그룹 A와 그룹 B를 말하게 되며, 그룹 A는 화요일, 수요일, 목요일, 금요일로 구성되며, 그룹 B는 토요일, 일요일, 월요일을 의미한다.

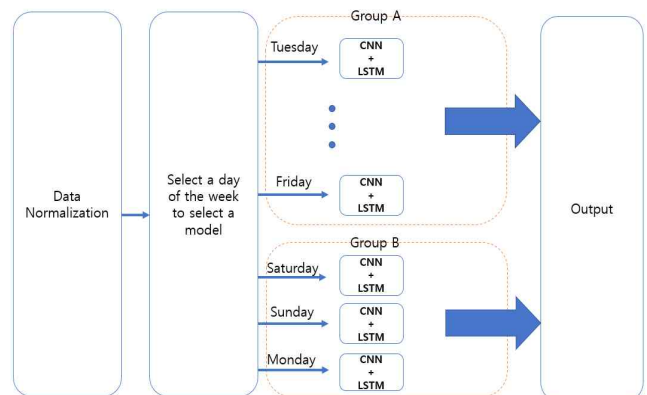


그림 4 STLC 모델 구성

Fig. 4 The structure of STLC

LSTM 모델의 경우, 그룹 A는 예측일 당일 및 과거3일의 데이터를 사용하기 때문에 LSTM 시퀀스길이를 96(24×4)으로 구성하였으며, 그룹 B는 예측일 당일 및 과거 7일의 데이터를 사용하기 때문에 시퀀스 길이를 192(24×8)로 설정하였다.

본 논문에서 제시한 STLC 모델은 그림 4와 같이 구성되며, 전력 수요 패턴을 반영한 CNN과 시간 및 기후 데이터에 따른 전력 수요 변화를 반영한 LSTM이 병렬적으로 예측을 수행하게 된다. 그 다음 각 모델의 정확도에 따른 가중치를 반영하여 최종 예측값을 출력하게 된다.

### 3. 사례연구

본 논문은 2018년 하절기 및 동절기의 전력수요를 예측을 수행하여 실측값과의 비교를 통해 STLC 모델의 성능을 검증하였고, 수요 예측에 관련된 기존 연구들과 성능을 비교하였다. 비록 기존 연구들과의 예측 기간이나 데이터 구성이 다르기 때문에 정확한 비교는 될 수 없지만, 일반적인 하루 전 예측 기법의 성능 수준을 보이기 위해 표 3에 다른 사례 연구들의 예측 성능을 제시하였다. 예측 성능에 대한 평가는 MAPE(Mean Absolute Percentage Error)를 기준으로 하며, MAPE에 대한 수식은 다음과 같다.

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{L_{forecast,i} - L_{actual,i}}{L_{actual,i}} \right| \times 100 [\%] \quad (2)$$

제안 모델의 실험 결과를 평가하고 비교하기 위해 관련된 기존 연구들의 내용을 표 3에 정리하였다.

표 3 기존 연구와의 비교[15]

Table 3 Comparison of previous researches

연구모델	특성 및 고려 사항	MAPE(%)
신경회로망[11]	요일 특성에 따른 학습케이스 분류 여름철 신경망 입력 값 추가	3월 : 1.21 8월 : 2.23 12월 : 1.69
뉴로-퍼지[13]	요일 특성에 따른 학습케이스 분류 초기화 구조 벡크 구축	1.48
신경회로망[14]	상관관계를 통한 입력변수 선별 및 전력 피크에 따른 온도 민감도 차등 적용	하절기 : 1.97 동절기 : 1.64
지수평활화[19]	평일 단기전력 수요 예측을 위한 지수평활화 모델 계수 선정	2.09 ~ 2.29
지수평활화[20]	다양한 정규화 방법에 따른 예측 정확도 비교	2.02

표 4는 모델별 MAPE 결과를 나타낸 것이다. 우선 CNN 모델의 결과를 살펴보면 하절기에 비해 동절기의 예측 정확도가 높음을 확인할 수 있다. CNN은 수요 패턴만을 입력으로 하기

때문에 해당 결과가 의미하는 바는 동절기의 수요 패턴의 변화가 더 적다는 것을 의미한다. 그 다음 LSTM 모델의 결과를 살펴보면, CNN과 마찬가지로 동절기의 예측 정확도가 하절기보다 높음을 확인할 수 있다. LSTM은 수요 및 기후데이터를 반영하였기 때문에 해당 결과가 의미하는 바는 하절기에는 기후 데이터 및 수요 패턴이외에 데이터가 필요하다는 것을 의미한다.




그림 5 2018년 하절기 예측 결과

Fig. 5 The result of prediction for summer in 2018




그림 6 2018년 동절기 예측 결과

Fig. 6 The result of prediction for winter in 2018

표 4 모델별 MAPE 결과 비교

Table 4 Comparison of each model's MAPE result

	LSTM	CNN	STLC
1월	1.36%	1.64%	1.31%
2월	1.50%	1.36%	1.24%
12월	1.31%	1.64%	1.31%
동절기	1.39%	1.55%	1.29%
7월	1.64%	1.69%	1.36%
8월	2.09%	2.33%	1.65%
9월	1.58%	1.27%	1.29%
하절기	1.77%	1.76%	1.43%
전체	1.58%	1.66%	1.36%

마지막으로 STLC 모델은 타 모델에 비해 동절기는 1.39%, 1.55%에서 1.29%로 개선되었으며, 하절기는 1.77%, 1.76%에서 1.43%로 개선되었음을 확인할 수 있다. 전체 평균 기준으로 기존의 LSTM이나 CNN과 비교한 결과 평균 오차율 기준 1.53%, 1.66%에서 1.36%로 개선되었다. 이는 CNN의 패턴 반영과 LSTM의 기후 변화 및 시간에 따른 특성을 동시에 반영하였고 각 모델의 예측 정확도에 따른 가중치를 반영하여 각 모델의 장점을

동시에 반영하였기 때문이다.

또한 기존 연구[14]와 비교했을 시 예측 오차가 하절기 1.97%, 동절기 1.64%에 비해 1.29%, 1.43%로 예측정확도가 향상되었음을 확인할 수 있다. 다른 연구들과는 예측 수행기간이 달라 정확한 비교는 어렵지만, 기존 연구들의 예측 성능보다 향상되었음을 확인하였다.

#### 4. 결 론

본 논문에서는 전력 수요 패턴을 반영하기 위해 CNN을 사용하였고, 기후 변화에 따른 특성을 반영하기 위해 LSTM을 사용하였다. 해당 모델들은 병렬 예측을 수행하고, 각 모델의 정확도에 따른 가중치를 반영하여 최종 예측값을 도출하는 방식의 모델을 제안하였다.

단기 전력 수요 모델은 크게 두 개의 그룹으로 나누어 데이터 구성을 달리하고, 요일별로 합성곱 신경망과 LSTM 모델을 두어 요일별 특성을 반영하고자 하였다. 제안 모델은 그룹 A의 경우, 예측일 기준 과거 3일의 전력 수요 데이터와 예측일 포함 과거 3일의 기후 데이터를 반영하여 예측을 수행하고, 그룹 B는 예측일 기준 과거 7일의 전력 수요 데이터와 예측일 포함 과거 7일의 기후 데이터를 반영하여 예측을 진행한다. 학습 효과를 높이기 위해 정규화(Normalization)를 수행하여 모든 데이터의 스케일을 0~1사이의 값으로 변환하였고 오버 피팅 문제를 방지하기 위하여 드롭아웃 및 정규화(Regularization)를 사용하였다.

학습 데이터는 2013~2017년까지의 기후 데이터 및 전력 수요 데이터를 사용하였고, 2018년 전력 수요 데이터를 가지고 모델의 성능을 검증하였다. 기후 데이터의 경우, 국내 주요도시 8개를 선정하여 2017년 전력 사용량에 따른 가중치를 산정하여 8개의 기후데이터를 하나의 대표 기후데이터로 변환하여 학습을 진행하였다.

본 논문은 특수일에 관한 사항은 고려하지 않았기 때문에 특수일에 영향을 받는 요일에 대해서는 예측을 수행하지 않았다.

예측 수행 결과 2018년 하절기 및 동절기 평균 MAPE는 1.36%로 예측기간이나 입력 데이터 구성이 다르기 때문에 정확한 비교는 불가능하지만 일반적인 단기 전력수요예측 모델과 비교해보았을 때 예측 정확도가 일반적인 수준보다 높음을 확인하였고, 한 가지 모델을 사용하는 것 보다 다양한 모델을 조합하여 사용하는 것이 예측 정확도를 높이는 방안임을 확인하였다. 향후 신재생 에너지 보급 확산에 따라 수요 변동량이 커질 것으로 예상된다. 이에 따라 신재생 에너지 관련 조도 및 풍속과 같은 기후데이터를 추가적으로 반영하고 수요 반응과 관련된 데이터 및 경제 지표를 반영한다면 더욱 정확한 예측이 가능해질 것으로 기대한다.

#### Acknowledgments

This work was supported by “Human Resources Program in Energy Technology” of the Korea Institute of Energy Technology Evaluation and Planning (KETEP), granted financial resource from the Ministry of Trade, Industry & Energy, Republic of Korea. (No. 20194030202370)

#### References

- [1] K. H. Kim, R. J. Park, S. W. Jo, and K. B. Song, “24-Hour Load Forecasting Algorithm Using Artificial Neural Network in Summer Weekdays,” *Journal of the Korean Institute of Illuminating and Electrical Installation Engineers* vol. 31, no. 12, 113-119, 2017.
- [2] C. H. Kim, “Estimating Short-Term Load Forecasting in Korea Using Multiple exponential Smoothing,” KERI, 2013.
- [3] S. Y. Kim, H. W. Jung, J. D. Park, S. M. Baek, W. S. Kim, K. H. Chon, and K. B. Song, “Weekly Maximum Electric Load Forecasting for 104 Weeks by Seasonal ARIMA Model,” *Journal of the Korean Institute of Illuminating and Electrical Installation Engineers*, vol. 28, no. 1, pp. 50-56, 2014.
- [4] C. N. Ko and C. M. Lee, “Short-term load forecasting using SVR (support vector regression)-based radial basis function neural network with dual extended Kalman filter,” *ELSEVIER Energy*, vol. 49, pp. 413-422, Dec. 2012.
- [5] H. Takeda, Y. Tamura, and S. Sato, “Using the ensemble Kalman filter for electricity load forecasting and analysis,” *Energy*, vol. 104, pp. 184-198, Apr. 2016.
- [6] S. Li, L. Goel, and W. Wang, “An ensemble approach for short-term load forecasting by extreme learning machine,” *ELSEVIER Applied Energy*, vol. 170, pp. 22-29, Mar. 2016.
- [7] Y. Feng and S. M. Ryan, “Day-ahead hourly electricity load modeling by functional regression,” *Applied Energy*, vol. 170, pp. 455-465, Mar. 2016.
- [8] V. N. Coelho, I. M. Coelho, B. N. Coelho, A. J. Reis, M. J. Enayatifar, and F. G. Guimaraes, “A self-adaptive evolutionary fuzzy model for load forecasting problems on smart grid environment,” *Applied Energy*, vol. 169, pp. 567-584, Feb. 2016.
- [9] Y. Yang, J. Che, Y. Li, Y. Zhao, and S. Zhu, “An incremental electric load forecasting model based on support vector regression,” *Energy*, vol. 113, pp. 796-808, Jul. 2016.
- [10] H. S. Tak, T. Y. Kim, H. G. Cho, and H. J. Kim, “A New Prediction Model for Power Consumption with Local Weather Information,” *Journal of THE Korea Contents Association*, vol. 16, no. 11, pp. 488-498, Nov. 2016.
- [11] S. Ha, K. Song, and H. Kim, “Short-Term Load Forecasting Using Neural Networks and the Sensitivity of Temperatures in the Summer Season,” *The Transactions of KIEE*, vol. 54A, no. 6, pp. 259-266, 2005.



- [12] J. Han and J. Baek, "The Load Forecasting in Summer Considering Day Factor," The Transactions of KAIS, vol. 11, no. 8, pp. 2793-2800, 2010.
- [13] Y. Park and B. Wang, "Neuro-Fuzzy Model based Electrical Load Forecasting System," The Transactions of KIIS, vol. 14, no. 5, pp. 553-538, 2004.
- [14] M. K. Kim and C. E. Hong, "The Artificial Neural Network based Electric Power Demand Forecast using a Season and Weather Informations," The Transactions of the Korean Institute of Electrical Engineers, vol. 53, no. 1, pp. 71-78, Jan. 2016.
- [15] SungMahn Ahn, "Deep Learning Architectures and Applications," Journal of Intelligence and Information Systems, vol. 22, no. 2, pp. 127-142, 2016.
- [16] H. Jang, S. Cho., "Automatic Tagging for Social Images using Convolution Neural Networks," Journal of KIIE, vol. 43, no. 1, pp. 47-53, 2016.
- [17] S. M. Chi, "Architectures of Convolutional Neural Networks for the Prediction of Protein Secondary Structures," Journal of the Korea Institute of Information and Communication Engineering, vol. 22, no. 5, pp. 728-733, May 2018.
- [18] Y. Kim, Y. Hwang, T. Kang, and K. Jung, "LSTM Language Model Based Korean Sentence Generation," The Journal of The Korean Institute of Communication Sciences vol. 41, no. 5, pp. 592-601, May 2016.
- [19] K. B. Song, O. S. Kwon, and J. D. Park, "Optimal Coefficient Selection of Exponential Smoothing Model in Short Term Load Forecasting on Weekdays," The Transactions of the Korean Institute of Electrical Engineers, vol. 62, 2013.
- [20] B. S. Kwon, R. J. Park, and K. B. Song, "Analysis of Short- Term Load Forecasting Accuracy Based on Various Normali- zation Methods," Journal of the Korean Institute of Illuminating and Electrical Installation Engineers, vol. 32, no. 6, 2018.



**김명수 (Myung Su Kim)**

1989년 3월 24일생. 2015년 건국대학교 전기공학과 졸업. 현재 건국대학교 대학원 전기공학과 박사과정.



**노재형 (Jae Hyung Roh)**

1969년 11월 10일생. 1993년 서울대 원자핵 공학과 졸업. 2002년 홍익대 전기공학과 졸업(석사). 2008년 Illinois Institute of Technology 전기공학과 졸업(박사). 현재 건국대학교 전기전자공학부 교수



**박종배 (Jong-Bae Park)**

1963년 11월 24일생. 1987년 서울대 전기공학과 졸업. 1989년 동 대학원 전기공학과 졸업(석사). 1998년 동 대학원 전기공학과 졸업(박사). 현재 건국대학교 전기전자공학부 교수

#### 저자소개



**김도현 (Dohyun Kim)**

1993년 8월 14일생. 2018년 건국대학교 전기공학과 졸업. 2019년 동 대학원 전기공학과 졸업(석사).



**조호진 (Ho Jin Jo)**

1993년 8월 20일생. 2018년 건국대학교 전기공학과 졸업. 2019년 동 대학원 전기공학과 졸업(석사).